



ADS03：倒排文件索引

来源：Materials/Student Slides/ADS03InvFileInd_Stu.ppt

课件范围：S1–S6、S7–S10、S11–S14、S15–S19；共 19 张幻灯片。

笔记按原课件顺序整理；S 编号指幻灯片顺序。

本讲路线图

- 全文扫描的问题 → 词项与文档的关系 → 倒排表及位置信息 → 索引构建、扩展与压缩 → 检索质量评价。

1. 从全文扫描到倒排文件 [S1–S6]

倒排文件索引（Inverted File Index）按“词项 → 出现它的文档”组织数据，使检索无需每次逐篇扫描全文。[S1–S3]

1.1 逐篇扫描与词项—文档矩阵 [S2–S4]

重要性：A · 必须掌握

查询 Computer Science 时，最直接的方法是逐页搜索这个字符串；文档多时，每次查询都要重复处理全部内容。词项—文档关联矩阵（Term-Document Incidence Matrix）改为预先记录某词是否出现于某篇文档：行是词项，列是文档，元素为 0 或 1。[S2–S4]

S4 的四篇文档中，silver 的位向量是 1010，truck 的位向量是 1011。按位与得到

$\text{silver AND truck} = 1010 \text{ AND } 1011 = 1010$

因此同时包含两词的是文档 1 和 3。这个表示法让布尔与查询很直观，但若词汇量和文档量都大，完整矩阵会包含大量零。[S4]

1.2 倒排表与文档频率 [S5]

重要性：A · 必须掌握

索引（Index）是根据给定词项定位文本的机制。倒排文件为每个词项维护出现位置的列表；最基础的形式只保存包含该词的文档编号，称为倒排表（Posting List）。词项到列表的入口集合是词典（Dictionary）。[S5]

对 S4 的样例，silver → {1,3}、truck → {1,3,4}，所以求交仍得 {1,3}。与完整矩阵相比，只保存出现过的文档编号，可避免为大量零项分配空间。[S4–S5]

课件表格写作 $\langle \text{Times}; \text{Documents} \rangle$ 。其中 silver 对应 $\langle 2; 1,3 \rangle$ ，虽然文档 3 中 silver 出现两次；这里的 Times=2 实际是文档频率（Document Frequency, DF），即包含该词的文档数，不是整个集合里的词次。[S5–S6]

1.3 位置倒排表与多词查询 [S6]

重要性：A · 必须掌握

若要找出并高亮含查询词的句子，可在倒排项中额外保存文档内词位。例如 `silver` 在文档 3 的位置为 (3;3,7)，表示该文档中第 3 和第 7 个词是 `silver`。词位信息能支持短语查询、邻近查询和结果片段定位。[S6]

核心原理

先按倒排表求出可能包含所有查询词的文档，再用位置列表核实词序或距离，避免扫描无关文档。

例如查询两个连续词 A B：先对两词的文档编号集合求交，仅保留共同文档；再在每篇候选文档内检查是否存在 A 的位置 p 与 B 的位置 $p + 1$ 。只求文档交集只能保证“同篇出现”，不能保证“连在一起”。[S6]

解释补充： S6 的位置表回答了“怎样打印并高亮句子”的问题，但词位本身还不足以恢复原句；实际展示时还需要保留或读取原文，并把词位映射回句子或字符偏移。

讲者备注指出，多词 AND 查询宜从文档频率最小的词项开始求交，较小的中间结果通常减少后续比较。[S6, 讲者备注]

2. 索引生成与受限内存处理 [S7–S10]

索引构建从逐文档分词开始，依次处理词形、停用词、词典查找和倒排项写入；内存不足时需要分块落盘并归并。[S7–S10]

2.1 基本索引生成器 [S7]

重要性：A · 必须掌握

核心原理

遍历每篇文档的词项：词不在词典时先加入词典，然后定位它的倒排表、写入当前文档或位置，最终把索引持久化。

```
for each document D:
    for each analyzed term T in D:
        if T is absent from dictionary:
            insert T into dictionary
        locate posting list of T
        add the occurrence information for T in D
write the inverted index to disk
```

课件把词法分析 (Token Analyzer)、停用词过滤 (Stop Filter)、词汇扫描、词典插入和内存管理列为生成过程的组成部分。[S7]

解释补充：若目标倒排表只保存唯一的文档编号，同一词在同一文档反复出现时不能重复插入文档号；应合并成一个文档项，并在其下维护出现次数或位置。课件伪代码中的“每读一词插入一个节点”是生成流程的简写。[S5–S7]

2.2 词形归一与停用词 [S8]

重要性：B · 重点理解

词干提取 (Stemming) 把不同词形尽量归并到统一形式，例如 `process / processing / processes / processed → process`。课件也把 `says / said / saying → say` 作为归一示例。建立索引与查询时需使用一致的词形处理规则，否则查询词可能无法命中已归一的词项。[S8]

停用词 (Stop Words) 是高频而区分度较低的词，如 `a、the、it`；过滤它们可减少索引规模。是否过滤取决于查询需求：若系统要支持精确短语，常见词的位置有时仍重要。[S8]

2.3 词典查找结构 [S9]

重要性：B · 重点理解

访问词项时，课件给出搜索树（如 B 树、B+ 树、Trie）和哈希 (Hashing) 两类词典组织方式，并提出比较其优缺点。[S9]

解释补充：哈希适合词项的平均常数时间精确查找，但不直接提供有序遍历；搜索树按键排序，便于范围或前缀相关操作，但单次查找通常需沿树高进行。实际性能还取决于碰撞、缓存、磁盘页布局及是否使用 Trie。

2.4 内存不足时的分块索引 [S10]

重要性：A · 必须掌握

核心原理

内存中的临时索引满时先排序并写成一个磁盘块，继续处理后续文档；最后对有序块进行归并，形成完整倒排索引。

1. 顺序读文档、分析词项，在内存中构建当前块索引。
2. 内存用尽时，把块按词项及倒排项顺序排序，写成 `BlockIndex[i]`，释放内存。
3. 所有文档处理完后，对磁盘上的有序块归并；相同词项的倒排项合并并保持文档编号有序。[S10]

讲者备注明确要求在写磁盘前先排序，使归并效率更高。内存块容量越大，块数通常越少，但占用内存更多。[S10，讲者备注]

3. 规模扩展、更新与压缩 [S11–S14]

文档集合继续增长时，索引可以按词项或文档分布到多节点；文档更新和空间压力又带来辅助索引与压缩技术。[S11–S14]

3.1 分布式索引的两种切分方式 [S11]

重要性：B · 重点理解

词项切分 (Term-Partitioned Index) 把不同词区间交给不同节点，如 A-c 与 x-z；查询需要访问包含查询词的节点。文档切分 (Document-Partitioned Index) 把不同文档编号区间交给不同节点，如 1-10000 与 10001-20000；每个节点为自己的文档子集建索引。[S11]

解释补充：词项切分便于定位某词的倒排表，但多词查询可能跨节点；文档切分可在各节点上并行处理同一查询，最后合并局部结果。二者的网络与负载代价依查询分布而变。[S11]

3.2 动态索引 [S12]

重要性：B · 重点理解

文档不断进入时，已有词项的倒排表要追加文档，新词项要进入词典；文档删除也要反映到检索结果。课件用主索引 (Main Index) 和辅助索引 (Auxiliary Index) 示意增量更新，并提出何时重建、怎样删除文档的问题。[S12]

解释补充：一个可行实现是让新文档先进入较小的辅助索引，查询同时读取主索引和辅助索引，再定期合并；删除可先记录待删除文档号，并在合并时清理。这是对图示问题的实现补充，具体合并阈值不由课件给定。

3.3 词典与倒排表压缩 [S13]

重要性：B · 重点理解

词典中相邻词可连接存储以减少重复的定长槽位开销，课件展示了把多个词拼接保存的示意。倒排表的文档编号一般递增，可只保存首个编号与后续差值：

文档编号： 2, 15, 47, ..., 58879, 58890, ...

间隔值： 2, 13, 32, ..., 11, ...

这叫间隔编码 (Gap Encoding)；多数间隔比绝对文档编号小，因此可以再用变长整数编码减少位数。[S13]

3.4 截断检索 [S14]

重要性：B · 重点理解

阈值截断 (Thresholding) 有两种示例：只取按权重排在前 x 的文档，或按频率排序后只处理一部分查询词。它减少处理量，却可能漏掉相关结果。只取前 x 文档不能保证完整布尔查询；只处理部分查询词则改变了原查询约束。[S14]

4. 检索系统的评价 [S15-S18]

检索系统既要衡量索引与查询速度，也要衡量返回结果是否真正符合信息需求。[S15]

4.1 性能、表达能力与相关性 [S15]

重要性：B · 重点理解

工程指标包括每小时索引文档数、查询延迟随索引规模的变化、索引占用空间，以及查询语言能否表达复杂需求并高效执行。相关性评价还要观察返回结果是否令用户满意；“找得快”和“找得准”是不同维度。[S15]

4.2 精确率与召回率 [S16–S17]

重要性：A · 必须掌握

相关性评价需要基准文档集合、基准查询集合，以及每个“查询—文档”对是否相关的判定。令 RR 为被检索且相关的文档数， IR 为被检索但不相关的数， RN 为未被检索但相关的数， IN 为未被检索且不相关的数。[S16]

核心原理

以“已经返回的结果”和“所有真正相关的文档”为两个不同分母，分别衡量结果纯度和覆盖程度。

$$\text{精确率 (Precision)} \quad P = \frac{RR}{RR + IR}, \quad \text{召回率 (Recall)} \quad R = \frac{RR}{RR + RN}.$$

精确率高表示返回结果中垃圾少；召回率高表示相关文档漏得少。例如 $RR=8$, $IR=2$, $RN=12$ ，则 $P = 8/10 = 0.8$, $R = 8/20 = 0.4$ ：前十条看起来较准，但还有十二篇相关文档没找到。[S16–S17]

解释补充：数值例子用于说明分母不同，不是课件表格中的实测数据。阈值提高时通常能减少不相关结果，却可能增加漏检；S17 的曲线示意这种取舍，不能保证任意方法都沿同一条曲线变化。

4.3 改进相关性的开放讨论 [S18]

重要性：C · 了解即可

S18 把“如何提高搜索结果相关性”留作讨论题。复习时可以从查询词处理、匹配证据、排序权重与评估数据集四方面思考，但具体方法及其效果需要另外设计和验证。[S18]

5. 阅读材料 [S19]

重要性：C · 了解即可

课件列出 `InvertedFileIndex.zip` 与若干倒排索引、压缩、Google File System 资料供进一步阅读。[S19]

本讲总结

- 倒排索引把词项映射到文档列表，避免每次查询扫描全文。[S2–S5]
- 词项—文档矩阵的按位与对应 AND 查询；倒排表求交只处理实际出现的文档号。[S4–S6]
- 位置信息支持短语与高亮；S5–S6 的 `Times` 是文档频率，不能误当词次。[S5–S6]
- 索引生成需分析词形、维护词典和倒排表；内存不足时先排序分块再归并。[S7–S10]
- 分布式切分、动态辅助索引、间隔编码与截断分别应对规模、更新、空间和查询代价。[S11–S14]

- 精确率看结果纯度，召回率看相关文档覆盖率。[S15–S17]

结构与适用条件速查

结构 / 方法	核心作用	代价或限制	来源
全文逐篇扫描	不预建索引	每次查询重复扫描集合	S2–S3
词项—文档矩阵	布尔运算可按位执行	大规模矩阵稀疏	S4
倒排表	只保存出现词项的文档	需维护词典和有序列表	S5–S7
位置倒排表	支持短语与高亮	增加索引空间	S6
分块排序归并	内存不足时建索引	产生磁盘写入与归并代价	S10
文档切分 / 词项切分	多节点分担索引	查询路由和结果合并	S11
间隔编码	压缩递增文档号	解码时需累加间隔	S13
阈值截断	限制查询处理量	可能丢失相关结果	S14

易错点

- silver $\rightarrow$ {1,3} 里的 2 是包含该词的文档数，文档 3 中重复出现两次不改变这个数字。[S5–S6]
- 两词出现在同一文档，只满足 AND；要确认相邻短语，需检查词位差。[S4–S6]
- 建索引时的分词、词形归一和停用词策略必须与查询处理保持一致。[S7–S8]
- 分块索引先排序再写盘，才能有效归并同词项的列表。[S10，讲者备注]
- 只返回前 x 条不保证完整布尔结果，也可能降低召回。[S14]
- 精确率分母为所有**已检索**文档，召回率分母为所有**相关**文档。[S16]

复习自测

1. 对 S4 的四篇文档，silver AND truck 为什么是文档 1 和 3？（来源：[S4]）
2. 倒排表中的文档频率、词项在某篇文档中的出现次数和位置分别记录什么？（来源：[S5–S6]）
3. 查询连续词组时，为什么不能只求两个倒排表的文档交集？（来源：[S6]）
4. 索引生成器何时向词典插入词项？同一词在一篇文档重复出现时怎样维护文档项？（来源：[S7]）
5. 内存不足时，为什么先排序再将块索引写到磁盘？（来源：[S10]）
6. 词项切分和文档切分分别以什么为分片键？（来源：[S11]）
7. 若 RR=30，IR=10，RN=20，精确率和召回率分别是多少？（来源：[S16]）

术语速查

术语	概念	来源
倒排文件索引 (Inverted File Index)	按词项列出出现该词的文档或位置	S5
词项—文档关联矩阵 (Term-Document Incidence Matrix)	词是否出现在文档中的 0/1 表	S4

术语	概念	来源
词典 (Dictionary)	词项到其倒排表的入口	S6-S7
倒排表 (Posting List)	某词对应的文档号与可选位置信息	S5-S7
文档频率 (Document Frequency, DF)	包含某词的文档数量	S5-S6
词干提取 (Stemming)	归并词的不同形态	S8
停用词 (Stop Words)	高频、通常区分度低的词	S8
间隔编码 (Gap Encoding)	将递增文档号改写为相邻差值	S13
精确率 (Precision)	返回结果中的相关比例	S16
召回率 (Recall)	相关文档中被返回的比例	S16

待核对

- [待核对 S14] 查询词截断示意只给出频率排序和 20%、40%、80% 阶段，未给出实际保留哪些词以及相应的结果；具体阈值策略需对照课堂说明。
- [待核对 S18] 这一页只有开放讨论题，没有列出被课程采纳的改进方案。